

Kompletné skriptá – Matematické princípy informatiky a aplikovaná informatika

Tento dokument je navrhnutý ako kompletný zdroj na prípravu na prijímacie skúšky. Obsahuje vysvetlenia, definície aj praktické poznámky.

1. Exploračná analýza dát (EDA)

Cieľ EDA

Exploračná analýza dát slúži na prvotné pochopenie dát. Nejde o formálne testovanie hypotéz, ale o získanie intuície o dátach.

Zameriava sa na identifikáciu chýb, extrémnych hodnôt, trendov a vzťahov.

Popisné charakteristiky

Stredné hodnoty: priemer (aritmetický), medián (prostredná hodnota), modus (najčastejšia hodnota).

Variabilita: rozptyl (variance) a smerodajná odchýlka (standard deviation) vyjadrujú rozptýlenie dát.

Kvartily rozdeľujú dáta na štyri časti.

Vizualizácia

Histogram: zobrazuje rozdelenie dát.

Boxplot: identifikuje medián, kvartily a outliersy.

Scatter plot: ukazuje vzťah medzi dvoma premennými.

Reziduá

Reziduum = skutočná hodnota mínus predikovaná hodnota.

Používajú sa na kontrolu kvality modelu.

Transformácie

Log transformácia sa používa pri silnej asymetrii.

Štandardizácia: premena na nulový priemer a jednotkovú odchýlku.

Normalizácia: škálovanie do intervalu (napr. 0–1).

Viacrozmerné techniky

PCA (analýza hlavných komponentov) znižuje dimenziu dát pri zachovaní variability. Používa sa aj faktorová analýza alebo t-SNE.

2. Pravdepodobnosť

Základy

Pravdepodobnosť je miera neistoty. Definuje sa na intervale 0 až 1.

Náhodná premenná

Diskrétna: nadobúda spočítateľné hodnoty.

Spojité: nadobúda hodnoty z intervalu.

Rozdelenie

Popisuje pravdepodobnosti jednotlivých hodnôt.

Normálne rozdelenie

Symetrické rozdelenie definované parametrami μ (priemer) a σ (odchýlka).

Veľa javov v prírode sa riadi približne normálnym rozdelením.

Centrálna limitná veta

Priemer dostatočne veľkej vzorky má približne normálne rozdelenie bez ohľadu na pôvodné rozdelenie.

Testovanie normality

Používajú sa testy ako Shapiro-Wilk alebo Kolmogorov-Smirnov.

Grafická metóda: Q-Q plot.

Odvožené rozdelenia

t-rozdelenie: používa sa pri malých vzorkách.

Chi-kvadrát rozdelenie: testy rozptylu.

F-rozdelenie: ANOVA.

3. Inferenčná štatistika

Základ

Inferenčná štatistika robí závery o populácii na základe vzorky.

Odhady

Bodové odhady: jedno číslo (napr. priemer).

Intervalové odhady: interval spoľahlivosti.

Testovanie hypotéz

H_0 : nulová hypotéza.

H_1 : alternatívna hypotéza.

p-hodnota: pravdepodobnosť pozorovania výsledku za platnosti H_0 .

Chyby

Chyba I. druhu: zamietneme pravdivú H_0 .

Chyba II. druhu: nezamietneme nepravdivú H_0 .

Parametrické vs neparametrické testy

Parametrické testy predpokladajú normálne rozdelenie.

Neparametrické testy sú robustnejšie.

Typy vzoriek

Nezávislé vs závislé (párové).

4. Štatistické metódy

Testy strednej hodnoty

t-test: porovnanie priemerov.

ANOVA: porovnanie viacerých skupín.

Testy rozptylu

F-test alebo Leveneho test.

Neparametrické alternatívy

Mann-Whitney test.

Wilcoxon test.

Kruskal-Wallis test.

Vzťahy medzi premennými

Korelácia: Pearson (lineárna), Spearman (monotónna).

Regresia: modelovanie závislosti.

5. Objavovanie znalostí (KDD)

Proces

1. Výber dát
2. Čistenie dát
3. Transformácia
4. Modelovanie
5. Interpretácia

CRISP-DM

Štandardný proces: business understanding → data → modeling → evaluation → deployment.

SEMMA

Sample, Explore, Modify, Model, Assess.

6. Data mining a ML

Typy metód

Klasifikácia: priradenie triedy.

Zhlukovanie: hľadanie skupín.

Predikcia: odhad budúcnosti.

Algoritmy

Rozhodovacie stromy.

Neurónové siete.

Bayesovské modely.

Asociačné pravidlá

Pravidlá typu: ak $A \rightarrow$ potom B.

7. Vyhodnotenie modelov

Metriky

Accuracy, Precision, Recall, F1-score.

Krížová validácia

k-fold cross validation znižuje overfitting.

Overenie predpokladov

Normalita, nezávislosť, homogenita.

8. Typy úloh

Deskripcia: sumarizácia dát.

Segmentácia: clustering.

Klasifikácia.

Predikcia.

Analýza závislostí.